大模型 API

OpenAI

- 基础介绍

快速开始	https://developers.openai.com/api/docs/quickstart
模型	https://developers.openai.com/api/docs/models
价格	https://developers.openai.com/api/docs/pricing
API SDK	https://developers.openai.com/api/docs/libraries

- 核心案例

提示词指南	https://developers.openai.com/api/docs/guides/prompt-guidance
案例：文本生成	https://developers.openai.com/api/docs/guides/text
案例：代码生成	https://developers.openai.com/api/docs/guides/code-generation
案例：视觉生成	https://developers.openai.com/api/docs/guides/images-vision
案例：音频生成	https://developers.openai.com/api/docs/guides/audio
案例：结构化输出	https://developers.openai.com/api/docs/guides/structured-outputs
案例：Responses API	https://developers.openai.com/api/docs/guides/migrate-to-responses
案例：Tools	https://developers.openai.com/api/docs/guides/tools https://developers.openai.com/api/docs/guides/function-calling

- Agents SDK

快速开始	https://developers.openai.com/api/docs/guides/agents https://developers.openai.com/api/docs/guides/agents/quickstart
Agent	https://developers.openai.com/api/docs/guides/agents/define-agents
Model	https://developers.openai.com/api/docs/guides/agents/models
Running agents	https://developers.openai.com/api/docs/guides/agents/running-agents
Sanbox agents	https://developers.openai.com/api/docs/guides/agents/sandboxes
Orchestration	https://developers.openai.com/api/docs/guides/agents/orchestration
Guardrails	https://developers.openai.com/api/docs/guides/agents/guardrails-approvals
Results and state	https://developers.openai.com/api/docs/guides/agents/results
Integrations and observability	https://developers.openai.com/api/docs/guides/agents/integrations-observability
Evaluate agent workflows	https://developers.openai.com/api/docs/guides/agent-evals
Voice agents	https://developers.openai.com/api/docs/guides/voice-agents
Agent Builder	https://developers.openai.com/api/docs/guides/agent-builder

- Tools

Web search	https://developers.openai.com/api/docs/guides/tools-web-search
MCP	https://developers.openai.com/api/docs/guides/tools-connectors-mcp
Skills	https://developers.openai.com/api/docs/guides/tools-skills
Shell	https://developers.openai.com/api/docs/guides/tools-shell
Computer use	https://developers.openai.com/api/docs/guides/tools-computer-use
File search	https://developers.openai.com/api/docs/guides/tools-file-search https://developers.openai.com/api/docs/guides/retrieval
Tool search	https://developers.openai.com/api/docs/guides/tools-tool-search
Code Interpreter	https://developers.openai.com/api/docs/guides/tools-code-interpreter

- Run and scale

Conversation state	https://developers.openai.com/api/docs/guides/conversation-state
Background mode	https://developers.openai.com/api/docs/guides/background
Streaming	https://developers.openai.com/api/docs/guides/streaming-responses
WebScoket mode	https://developers.openai.com/api/docs/guides/websocket-mode
Webhooks	https://developers.openai.com/api/docs/guides/webhooks
File inputs	https://developers.openai.com/api/docs/guides/file-inputs
Context management	https://developers.openai.com/api/docs/guides/compaction https://developers.openai.com/api/docs/guides/token-counting https://developers.openai.com/api/docs/guides/prompt-caching
Prompting	https://developers.openai.com/api/docs/guides/prompting https://developers.openai.com/api/docs/guides/prompt-engineering https://developers.openai.com/api/docs/guides/citation-formatting
Reasoning	https://developers.openai.com/api/docs/guides/reasoning https://developers.openai.com/api/docs/guides/reasoning-best-practices

- **Chat Completion API**

参数名	类型 / 可选值	含义
`messages`	array	对话历史消息列表，每条包含 `role`（developer/system/user/assistant/tool/function）和 `content`。支持文本、图像、音频等多模态内容。
`model`	string	使用的模型 ID，如 `gpt-4o`、`o3`、`gpt-5.4` 等，决定能力、性能与定价。
`temperature`	number (0–2)	采样温度。越高输出越随机，越低越确定。建议与 `top_p` 二选一调整。
`top_p`	number (0–1)	核采样概率质量阈值。例如 `0.1` 表示只考虑前 10% 概率的 token。
`n`	integer	为每条输入消息生成的聊天完成选项数量（默认 1）。越多成本越高。
`stop`	string/array	停止生成的 token 序列（最多 4 个），返回的文本不包含该序列。
`max_tokens`	integer	**已弃用**。生成的最大 token 数。被 `max_completion_tokens` 替代。
`max_completion_tokens`	integer	生成的最大 token 总数，包含可见输出和推理 token。
`stream`	boolean	是否启用流式输出（SSE），实时返回生成内容。
`logprobs`	boolean	是否返回输出 token 的对数概率。
`top_logprobs`	integer (0–20)	每个 token 位置返回的最可能 token 数量，需 `logprobs=true`。
`seed`	integer	确定性采样种子（Beta），配合 `system_fingerprint` 可复现结果。
`tools`	array	模型可调用的工具列表，如函数工具（function）或自定义工具（custom）。
`tool_choice`	"none" / "auto" / "required" / object	控制模型是否调用工具：`"none"` 不调用，`"auto"` 自动决定，`"required"` 必须调用，或指定具体工具。
`parallel_tool_calls`	boolean	是否启用并行工具调用（函数调用）。
`response_format`	object	指定输出格式：`{"type":"text"}` 文本；`{"type":"json_object"}` JSON 模式；`{"type":"json_schema", ...}` 结构化输出。
`frequency_penalty`	number (-2 – 2)	根据 token 已有频率惩罚新 token，降低重复相同行的概率。
`presence_penalty`	number (-2 – 2)	根据 token 是否已出现惩罚新 token，鼓励谈论新主题。
`logit_bias`	map	将 token ID 映射到偏置值（-100 到 100），改变其生成概率。
`user`	string	**正被替代**。终端用户标识，用于缓存和安全。建议改用 `prompt_cache_key` 或 `safety_identifier`。

`prompt_cache_key`	string	用于缓存相似请求，提高缓存命中率。
`prompt_cache_retention`	"in_memory" / "24h"	提示缓存的保留策略，`"24h"` 可延长至 24 小时。
`safety_identifier`	string	稳定标识符，帮助检测违反使用策略的用户（建议哈希处理）。
`store`	boolean	是否存储本次请求输出，用于模型蒸馏或评估。
`metadata`	object	最多 16 个键值对，附加结构化信息，可被 API 或仪表板查询。
`service_tier`	"auto" / "default" / "flex" / "scale" / "priority"	服务处理层级，影响性能与定价。
`reasoning_effort`	"none"/"minimal"/"low"/"medium"/"high"/"xhigh"	约束推理模型的思考强度，降低可提升速度和减少推理 token。
`verbosity`	"low" / "medium" / "high"	控制回答的详细程度。
`modalities`	array["text", "audio"]	输出模态。`gpt-4o-audio-preview` 支持同时输出文本和音频。
`audio`	object	音频输出参数，包含 `format`（如 wav/mp3）和 `voice`（内置或自定义语音 ID）。
`web_search_options`	object	联网搜索工具选项，如搜索上下文大小（`search_context_size`）和用户位置（`user_location`）。
`prediction`	object	静态预测输出内容，用于快速匹配和生成已知内容（如文件重生成）。
`function_call`	deprecated	已弃用，改用 `tool_choice`。强制模型调用指定函数。
`functions`	deprecated	已弃用，改用 `tools`。函数定义列表。

- **Responses API**

参数名	类型 / 可选值	含义
`model`	string	使用的模型 ID，如 `gpt-4o`、`o3-mini`、`gpt-5.4` 等，决定能力与定价。
`input`	string / array	模型输入，可以是纯文本字符串，或包含文本、图像、文件的多模态内容列表（支持 `user` / `assistant` / `system` / `developer` 角色）。
`instructions`	string	系统或开发者指令，插入到模型上下文中，优先级高于用户消息。
`conversation`	string / object	所属对话的 ID。可自动管理多轮对话上下文。不能与 `previous_response_id` 同时使用。
`previous_response_id`	string	前一次响应的 ID，用于构建多轮对话。不能与 `conversation` 同时使用。
`store`	boolean	是否存储本次响应，便于后续检索（如评估、蒸馏）。
`stream`	boolean	是否启用流式输出（SSE），实时返回生成内容。
`stream_options`	object	流式选项，包含 `include_obfuscation`（是否添加随机字符以均衡载荷大小）。
`background`	boolean	是否在后台运行模型响应（异步处理）。
`temperature`	number (0–2)	采样温度。越高输出越随机，越低越确定。
`top_p`	number (0–1)	核采样概率阈值。例如 `0.1` 只考虑前 10% 概率的 token。
`max_output_tokens`	number	生成的最大 token 总数，包含可见输出和推理 token。
`max_tool_calls`	number	单次响应中允许调用的内置工具总数上限（跨所有工具）。
`truncation`	`"auto"` / `"disabled"`	截断策略：`auto` 自动丢弃早期内容以适应上下文窗口；`disabled` 超限则报错。
`parallel_tool_calls`	boolean	是否允许模型并行调用多个工具。
`text`	object	文本响应配置，包含 `format`（输出格式）和 `verbosity`（详细程度）。
`text.format`	object	输出格式：`{"type":"text"}` 纯文本；`{"type":"json_object"}` JSON 模式；`{"type":"json_schema", ...}` 结构化输出。
`text.verbosity`	`"low"` / `"medium"` / `"high"`	控制响应详细程度。
`tools`	array	模型可调用的工具列表，包括内置工具（文件搜索、网页搜索、代码解释器、图像生成、计算机控制等）、MCP 工具、函数调用（自定义工具）等。

`tool_choice`	`"none"` / `"auto"` / `"required"` / object	控制工具选择：`none` 不调用；`auto` 自动决定；`required` 必须调用；或指定具体工具（函数 /MCP/ 自定义）。
`reasoning`	object	推理模型配置，包含 `effort`（推理强度）和 `summary`（摘要类型）。
`reasoning.effort`	`"none"` / `"minimal"` / `"low"` / `"medium"` / `"high"` / `"xhigh"`	约束推理模型的思考强度，降低可提升速度、减少推理 token。
`reasoning.summary`	`"auto"` / `"concise"` / `"detailed"`	推理过程的摘要类型，用于调试和可解释性。
`prompt`	object	引用可复用的提示模板，包含 `id`、`variables`（变量映射）和 `version`（版本）。
`prompt_cache_key`	string	用于缓存相似请求，提高缓存命中率。
`prompt_cache_retention`	`"in_memory"` / `"24h"`	提示缓存的保留策略，`"24h"` 可延长至 24 小时。
`safety_identifier`	string	稳定标识符，帮助检测违反使用策略的用户（建议哈希处理）。
`metadata`	object	最多 16 个键值对，附加结构化信息，可被 API 或仪表板查询。
`service_tier`	`"auto"` / `"default"` / `"flex"` / `"scale"` / `"priority"`	服务处理层级，影响性能与定价。
`include`	array	指定额外输出数据，如 `file_search_call.results`、`web_search_call.action.sources`、`message.output_text.logprobs`、`reasoning.encrypted_content` 等。
`top_logprobs`	integer (0–20)	每个 token 位置返回的最可能 token 数量（需模型支持）。
`context_management`	array	上下文管理配置，目前仅支持 `compaction` 类型及 `compact_threshold` 触发阈值。
`user`	string	**已被 `safety_identifier` 和 `prompt_cache_key` 替代**。终端用户标识，用于缓存和安全。

Anthropic

https://platform.claude.com/docs/en/api/beta/messages/create

后续补充

DeepSeek

- 基础介绍

快速开始	https://api-docs.deepseek.com/zh-cn/
模型 & 价格	https://api-docs.deepseek.com/zh-cn/quick_start/pricing
限速	https://api-docs.deepseek.com/zh-cn/quick_start/rate_limit
API SDK	https://developers.openai.com/api/docs/libraries

- 核心案例

思考模式	https://api-docs.deepseek.com/zh-cn/guides/thinking_mode
多轮对话	https://api-docs.deepseek.com/zh-cn/guides/multi_round_chat
对话前缀续写（Beta）	https://api-docs.deepseek.com/zh-cn/guides/chat_prefix_completion
FIM 补全（Beta）	https://api-docs.deepseek.com/zh-cn/guides/fim_completion
JSON Output	https://api-docs.deepseek.com/zh-cn/guides/json_mode
Tool Calls	https://api-docs.deepseek.com/zh-cn/guides/tool_calls
上下文硬盘缓存	https://api-docs.deepseek.com/zh-cn/guides/kv_cache

- API

功能 / 分类名称	API 文档链接
基本信息	https://api-docs.deepseek.com/zh-cn/api/deepseek-api
对话（Chat）	https://api-docs.deepseek.com/zh-cn/api/deepseek-api#
补全（Completions）	https://api-docs.deepseek.com/zh-cn/api/deepseek-api#
模型（Model）	https://api-docs.deepseek.com/zh-cn/api/deepseek-api#

阿里云百炼

https://bailian.console.aliyun.com/

字节火山

https://www.volcengine.com/product/ark